SelfCheckGPT 词频分支部分复现报告

G20 · P25 原设置部分复现 联系人 赖轲楠（1120231192）

张昊 1120233632 赖轲楠 1120231192
李方洲 1120232973 李沐曦 1120232679

1 论文来源与复现问题

Manakul、Liusie 和 Gales 在 EMNLP 2023 发表 SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models [1]。本文研究如何在没有外部事实数据库、也无法读取被检测模型内部概率的情况下，为生成文本中的每个句子给出幻觉风险分数。输入是待检测文本与同一模型的多个采样输出，输出为句级一致性分数。

本次只复现 unigram 分支，不将局部实验称为整篇论文复现。原文定位为第5.3节 n-gram、表2的 Unigram(max) 行、附录D表7的 Avg/Max 1-gram 行，以及附录图8的采样数量实验。要检验的问题是：最大负对数词频是否比平均负对数词频更能区分非事实句；增加已有参考输出数量是否改善排序。

核心算法

沿用作者公开的 WikiBio 生成和采样文本 [2]。每篇原文 R 与 K 个参考输出 S 合并统计小写词频，保留标点。设词 t 的出现次数为 c(t)，总词数为 T，则 p(t)=c(t)/T。包含原文是官方代码的原始设置 [3]，可避免原文词语在参考中未出现时产生零概率。

基线 Avg = 一句中所有词的 -ln p(t) 的平均值。
目标 Max = 一句中最大的 -ln p(t)。
分数单位为 nats，越大表示与采样输出越不一致。

平均评分会受常见词影响，最大评分关注一句中最少见的词，因此可能更敏感于错误数字与专名。但低频并不等于错误；如果模型在多个采样中重复同一错误，算法也可能给它较低风险。这里的“零资源”指无需外部事实库，不是无需计算或采样。

2 方法与实验设置

数据使用作者公开 v3 evaluation 集的全部238篇、1,908句，每篇20个参考输出。accurate 为516句，minor_inaccurate 为631句，major_inaccurate 为761句。前者映射为0，后两者映射为非事实正类1，共1,392句（72.96%）。沿用作者句子边界与标签，不删除截断句。WikiBio 参照只用于事后案例解释，不输入评分器。

项目	原论文	本次设置及影响
数据	238篇与人工句级标签	使用公开全部数据；ID、字节哈希与抽样索引落盘
生成模型	GPT-3 text-davinci-003	复用作者生成与采样文本，不重新调用模型
分支与代码	unigram Avg/Max；20参考	固定作者commit；K=1/3/5消融，K=20锚点
分词与预算	spaCy；小写词频	spaCy 3.8.11 / en_core_web_sm 3.8.0；CPU运行
随机性	原文未提供完整抽样种子细节	seed=42/43/44；同一篇内嵌套随机前缀
指标	AUC-PR及篇级相关性	主报AP/AUROC，另存梯形PR-AUC与相关性
检验范围	多分支整体研究	只验证词频分支，不能推论NLI或Prompt结果

每篇以 NumPy SeedSequence([seed, doc_id]) 固定参考排列，K=1、3、5取相同排列的前缀；两种评分共享同一输入。K=20包含全部参考输出，排列不改变词频，故只运行一个种子。数据未用于训练或选择参数，也没有根据测试标签选择分类阈值。公开评估集的多配置观察属于复现与探索性比较，不声称为新盲测。

AP 使用 average_precision_score；AUROC使用 roc_auc_score。两者均以非事实为正类，分数方向保持不变；事实类AP另用相反分数计算。AP与梯形积分的PR-AUC不是完全相同的数值，因此原文AUC-PR与本次AP需区分。三种子报告均值与样本标准差；K=5、seed=42另作按篇聚类、1,000次配对bootstrap，保留同篇句子的相关性。

3 主要结果与原文对照

表1给出全部1,908句的真实运行结果。K=1/3/5的误差为三个参考抽样种子的样本标准差，单位为百分点；不是模型重新训练的波动。无技能参照的AP为正类占比72.96%，AUROC为50%。

评分	参考K	非事实 AP (%)	AUROC (%)
Avg 基线	1	72.65 ± 0.67	49.46 ± 0.52
Max 目标	1	79.00 ± 0.66	60.86 ± 0.79
Avg 基线	3	76.56 ± 0.27	57.08 ± 0.55
Max 目标	3	82.51 ± 0.55	66.92 ± 0.72
Avg 基线	5	78.43 ± 0.47	60.23 ± 0.51
Max 目标	5	84.04 ± 0.65	69.87 ± 0.30

表1 三种子句级检测结果，238篇、1,908句

K=5时Max的平均AP比Avg高5.61个百分点，平均AUROC高9.64个百分点。固定seed=42的配对按篇bootstrap中，AP差值95%区间为[3.93, 9.47]个百分点，AUROC差值区间为[6.70, 14.20]个百分点。该区间支持本公开数据上Max的排序优势，不代表跨数据集或跨模型的普遍结论。

20参考锚点	原文AUC-PR (%)	本次AP (%)	本次梯形PR-AUC (%)
Avg 1-gram（表7）	81.52	81.54	81.52
Max 1-gram（表2/7）	85.63	85.64	85.62

表2 20参考输出与论文数值近似重现，指标实现差异须保留

Max的篇级Pearson=0.6472、Spearman=0.6491，接近原文的0.6471与0.6491。Avg的Pearson=0.4068、Spearman=0.3923，也接近表7。评分通过3篇6项官方实现一致性核验，最大绝对差约为数值舍入量级，小于1e-12。这里据此称“近似重现”，不把四舍五入后的接近说成逐项完全相同。

运行证据：results/metrics_by_run.csv、summary.csv、bootstrap_ci.json、upstream_verification.json；逐句分数与标签见predictions.jsonl。报告数字均能回到对应K、seed与ID。

4 采样数量消融与资源分析

本次只改变使用参考输出的数量K，其余分词、数据、标签、算法和种子保持一致。图1显示，Max的AP从K=1的79.00%上升到K=3的82.51%，再上升到K=5的84.04%；Avg则从72.65%上升至76.56%和78.43%。这一单因素对照支持更多已有参考输出有助于区分真实词汇共识与偶然出现。

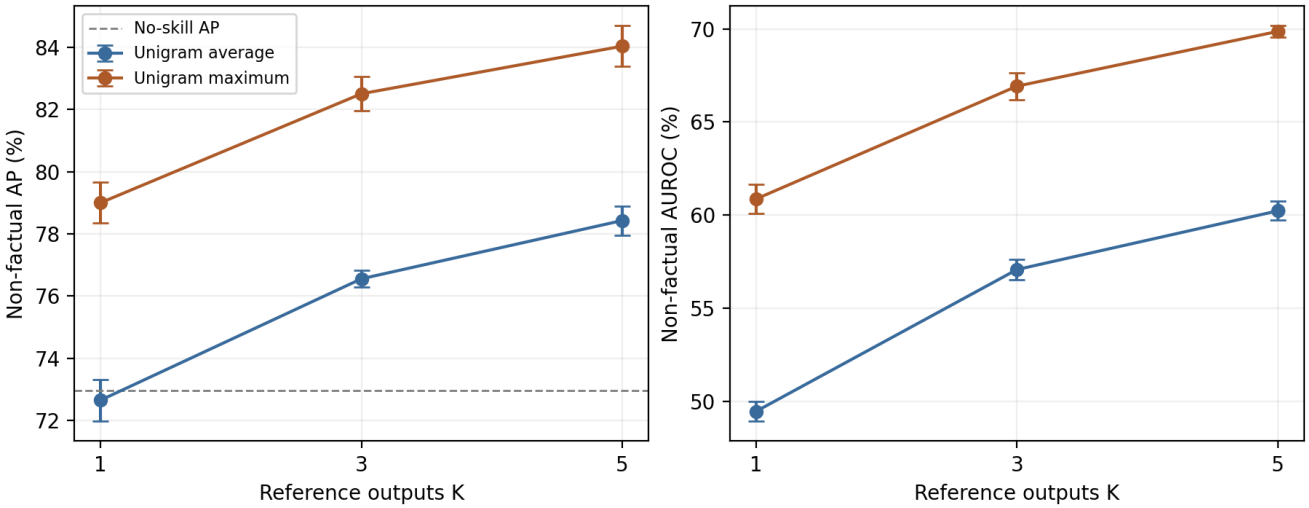


图1 K=1/3/5预算曲线，三种子均值与标准差，238篇、1,908句

K=1时Avg的AUROC为49.46%，接近无技能水平；即使其AP有72.65%，也不能据此认为效果很好，因为非事实句本来就占72.96%。Max在各预算下均优于Avg，但从3到5的增益小于从1到3的增益。受预算点与样本限制，不能据此声称已找到最优K或证明所有更大K都单调提升。

服务器需求与真实耗时

运行机器为Windows 11、约32 GB内存、CPU版PyTorch且无可用CUDA。本分支不依赖PyTorch训练或大模型权重，服务器与付费API均非必需。3篇试跑约5.11秒；完整评分约127.27秒，其中加载与分词约121.91秒；评价与1,000次bootstrap约5.21秒。首次下载和安装不计入上述运行时间。

实现缓存了全部文本的分词统计。因此每个配置的0.04—0.17秒只是缓存后的词频合并与评分耗时，不是端到端延迟，也不能用它估计新生成文本的API成本。K增加意味着可用参考文本更多；本次复用已公开文本，所以新增生成请求数始终为0。

后续若选做BERTScore，可再评估GPU加速；若选做重新生成或Prompt分支，需要额外模型/API资源，也会引入模型版本变化。本次课程限定任务已通过CPU的unigram路线覆盖，无需为更大模型购买服务器。

5 错误分析与结论

正文选取三例说明评分边界，完整12例见附录与results/cases.json。所有作者标签均原样保留，分数为K=5、seed=42的nats。这里的“错误”指排序表现不理想，不是使用调参分类阈值后计算的误报或漏报。

ID与作者标签	输入摘录	Avg / Max
58488:1 minor_inaccurate	She won a bronze medal in the 100-metre breaststroke at the 2012 Summer Olympics in London.	3.903 / 5.093
10582:0 accurate	Anne de Gaulle (1928–1948) was the daughter of French President Charles de Gaulle and his wife Yvonne de Gaulle.	4.675 / 7.144
2704:5 major_inaccurate	He was a member of the Indian delegation to the United Nations in 1950.	3.862 / 6.979

案例58488:1：原始WikiBio参照记载该运动员在伦敦奥运会100米蛙泳半决赛后的加赛被淘汰，生成句却说获得铜牌。奥运会、蛙泳和伦敦等常见词能够反复出现，低频检测并未直接验证“获得铜牌”这个关系，Max仍较低。

案例10582:0：作者标为准确的Anne de Gaulle生卒年和亲属信息得到较高Max。选中的参考输出之一错误地写为1928—1945年，与原文1948年相冲突。这说明参考文本本身也会幻觉，真实但在采样中少见的细节可能被惩罚。

案例2704:5：同一句Avg仅3.862，而Max为6.979。大量常见语法词可降低平均值，单个稀有细节则能被Max突出。WikiBio参照描述的是公务员C. V. Ananda Bose，采样之一却把他写成1897年出生的自由运动人物，提示同名人物混淆；此例只作为已给标注和文本的事后解释。

结论、限制与学习体会

证据支持：本公开数据上Max优于Avg，1/3/5参考消融呈改善趋势，20参考设置近似重现论文词频分支。限制包括单一人物传记域、同一旧版生成模型、样本量有限、人工标签与截断句边界，以及词频方法不理解关系。下一步可预先固定同一组参考索引，在独立数据上比较词频与BERTScore。

本次纠正了两个具体误解：AP达到70%不代表超过无技能基线；“零资源”也不等于零计算。官方一致性核验还确认，漏掉待检测原文会改变统计与零概率处理。

参考文献

[1] Potsawee Manakul, Adian Liusie, Mark Gales. 2023. SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. EMNLP 2023, pp.9004–9017. https://aclanthology.org/2023.emnlp-main.557/ DOI:10.18653/v1/2023.emnlp-main.557.

[2] Manakul et al. WikiBio GPT-3 Hallucination Dataset v3. CC-BY-SA-3.0. https://huggingface.co/datasets/potsawee/wiki_bio_gpt3_hallucination （取得日期2026-11-05）.

[3] potsawee/selfcheckgpt. MIT. Commit 19b492a2a380931bf1ed0ca94a9565c9aa7b03e1. https://github.com/potsawee/selfcheckgpt .

[4] 自然语言处理项目实践2026. 候选论文P25与提交要求. https://nlp.hltbit.top/2026/materials/w01/classroom/papers.html ; 同目录 requirements.html、report-template.md、presentation-template.pptx。

[5] spaCy. English pipelines and tokenization. https://spacy.io/models/en ; https://spacy.io/usage/linguistic-features .

[6] scikit-learn. average_precision_score / roc_auc_score. https://scikit-learn.org/stable/modules/model_evaluation.html .

附录A 最小运行与证据索引

解压后进入NLP2026_G20_P25目录。先创建Python 3.12评分环境并安装requirements.txt；再创建独立评价环境安装requirements-evaluation.txt，以保留实际NumPy版本。数据已随包提供，不需要下载权重。完整安装命令见README.md。

评分环境：python -m venv .venv；.venv\Scripts\python.exe -m pip install -r requirements.txt

试跑：.venv\Scripts\python.exe code/run_experiment.py --limit 3 --output results/pilot --verify-upstream

主实验：.venv\Scripts\python.exe code/run_experiment.py --verify-upstream

评价环境：python -m venv .eval；.eval\Scripts\python.exe -m pip install -r requirements-evaluation.txt

评价：.eval\Scripts\python.exe code/evaluate.py

核验：.eval\Scripts\python.exe code/verify_results.py

预期输出：19,080条逐句结果，10组K/seed组合，各含1,908句；两种方法分数记录在同一行。指标总计20行。两次环境的实际版本、耗时分别见environment.json、evaluation_environment.json。仅重新评价不需重复评分；不修改标签来让结果接近原文。

附录B 十二个完整案例索引

每例完整句子、标签、两种分数、参考文本和原始WikiBio参照均保存在results/cases.json及cases.md。下表保留全部12例索引与输入；案例ID为人物ID:从0开始的句序。

1. 341:12 major_inaccurate 低分非事实句
输入：He was a member of the Indian delegation to the
Avg=3.6107；Max=4.9646；K=5；seed=42。
解释：在非事实句中最大负对数词频较低，词汇重复不能排除事实错误。

2. 58488:1 minor_inaccurate 低分非事实句
输入：She won a bronze medal in the 100-metre breaststroke at the 2012 Summer Olympics in London.
Avg=3.9033；Max=5.0927；K=5；seed=42。
解释：在非事实句中最大负对数词频较低，词汇重复不能排除事实错误。

3. 42398:1 major_inaccurate 低分非事实句
输入：He played college basketball for the University of Detroit Mercy.
Avg=4.0824；Max=5.1829；K=5；seed=42。
解释：在非事实句中最大负对数词频较低，词汇重复不能排除事实错误。

4. 71763:3 major_inaccurate 低分非事实句
输入：Fite was born in Los Angeles, California.
Avg=4.1963；Max=5.3366；K=5；seed=42。
解释：在非事实句中最大负对数词频较低，词汇重复不能排除事实错误。

5. 10582:0 accurate 高分事实句
输入：Anne de Gaulle (1928–1948) was the daughter of French President Charles de Gaulle and his wife Yvonne de Gaulle.
Avg=4.6747；Max=7.1436；K=5；seed=42。
解释：在人工作为事实标注的句子中得分较高，低频专名或细节可能造成误报。

6. 3513:3 accurate 高分事实句
输入：He competed in the Italian Formula Three Championship from 1992 to 1994, and then moved to the International Formula 3000 Championship in 1995.
Avg=4.3697；Max=7.1277；K=5；seed=42。
解释：在人工作为事实标注的句子中得分较高，低频专名或细节可能造成误报。

7. 19109:0 accurate 高分事实句
输入：Moisés Kaufman (born November 21, 1963) is a Venezuelan-American director, playwright, and screenwriter.
Avg=4.5370；Max=7.0800；K=5；seed=42。
解释：在人工作为事实标注的句子中得分较高，低频专名或细节可能造成误报。

8. 2831:12 accurate 高分事实句
输入：He has also been credited with helping to develop the careers of many NFL players, including Hall of Fam
Avg=5.3319；Max=7.0707；K=5；seed=42。
解释：在人工作为事实标注的句子中得分较高，低频专名或细节可能造成误报。

9. 2704:5 major_inaccurate 平均与最大评分分歧
输入：He was a member of the Indian delegation to the United Nations in 1950.
Avg=3.8625；Max=6.9791；K=5；seed=42。
解释：最大评分突出最稀有词，平均评分会被常见词稀释。

10. 4048:7 minor_inaccurate 平均与最大评分分歧
输入：He was consecrated Bishop of New York in 1838, and was made Archbishop of New York in 1842.
Avg=3.9454；Max=7.0596；K=5；seed=42。
解释：最大评分突出最稀有词，平均评分会被常见词稀释。

11. 1959:3 minor_inaccurate 平均与最大评分分歧
输入：He finished third in the championship in 2009, and second in 2010.
Avg=4.0120；Max=7.0003；K=5；seed=42。
解释：最大评分突出最稀有词，平均评分会被常见词稀释。

12. 49037:2 minor_inaccurate 平均与最大评分分歧
输入：Sewall was born in Bath, Maine, the son of Hannah and Samuel Sewall.
Avg=4.0773；Max=7.0139；K=5；seed=42。
解释：最大评分突出最稀有词，平均评分会被常见词稀释。

341:12和2831:12为原数据中的截断句，未擅自修复或移除；不能只依靠当前摘录重新判断作者标签。前三类各按分数极值/分歧选4例，尽量选择不同人物，属于事后诊断而非新的代表性随机样本。

附录C 成员分工

本项目的工作包括论文与方法梳理、环境配置与主实验、指标与消融分析、错误案例与汇报材料整理，具体分工如下。

成员	负责内容	对应材料与主要问题
张昊 1120233632	论文理解与原文定位	§5.3、表2/7、图8；解释黑盒、零资源与事实边界
赖轲楠 1120231192	联系人；环境、主实验与代码	run_experiment.py、pilot、upstream_verification；解释原文计数与抽样
李方洲 1120232973	指标、消融与统计	evaluate.py、summary、bootstrap_ci；解释正类、AP与不确定性
李沐曦 1120232679	案例、汇报与证据演示	cases.json、slides.pptx、讲稿；解释参考幻觉与排序边界

项目完成238篇、1,908句的评分与评价，保存19,080条逐句记录、12例完整案例、采样索引和原始日志。报告、代码、配置和汇报材料按同一组实验结果整理。

附录D 代码来源与AI使用说明

原作者modeling_ngram.py在code/upstream/原样保留并附MIT许可。改动为一次加载与分词缓存、固定数据哈希、嵌套采样、逐句日志、指标与按篇bootstrap；评分逻辑保留作者设置，并与原实现核对。数据采用CC-BY-SA-3.0；PPT依据课程7页模板修改。没有使用其他小组的代码或数字。

使用Codex辅助资料检索、代码编写、实验执行和文稿整理。报告数值来自本次运行日志，评分实现通过与作者代码的逐句对照检查。

提交事项：最终包应命名NLP2026_G20_P25.zip，由联系人于2026-11-22 24:00前上传延河课堂并确认提交，在登记表填写教师可访问的链接。项目地址为github.com/yanguanyue/selfcheckgpt-reproduction-g20-p25。