SelfCheckGPT 词频分支部分复现

SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models

Manakul, Liusie, Gales · EMNLP 2023

G20 · P25 · 原设置部分复现

张昊、赖轲楠、李方洲、李沐曦

研究问题与复现范围

输入：原生成文本与同一模型的公开采样文本
输出：逐句非事实风险分数，越大风险越高
原文：§5.3、表 2、附录 D 表 7 与图 8
问题：最大词频评分是否优于平均评分？
范围：unigram 分支；参考预算 K=1 / 3 / 5

核心方法

共同步骤：合并原文与 K 个参考，统计小写词频
词概率：p(t) = 出现次数 / 总词数；保留标点
基线 Avg：一句中 -ln p(t) 的平均值
目标 Max：一句中最大的 -ln p(t)
机制：突出稀有细节；一致性不能保证真实性

实验设置与原文差异

数据：238 篇 / 1,908 句，沿用作者标签和句子
正类：轻微或严重不准确，占 72.96%
配置：CPU；K=1/3/5；seed=42/43/44；嵌套采样
指标：非事实 AP、AUROC；三种子均值 ± 标准差
差异：复用公开文本，不新生成；另跑 K=20 锚点

主要结果

非事实为正类；AP 与 AUROC 越高越好

实验	参考输出	PR 指标 / AUROC (%)	口径与证据
原论文 Max	K=20	85.63 / 未报告	AUC-PR；表 2
本次 Avg	K=5	78.43±0.47 / 60.23±0.51	AP；三种子
本次 Max	K=5	84.04±0.65 / 69.87±0.30	AP；三种子

采样预算与代表性错误

只改变参考数量 K，其余数据与评分保持一致
Max AP：K=1 79.00% → K=3 82.51% → K=5 84.04%
58488:1：奥运铜牌描述错误，Max 仍低至 5.09
10582:0：准确的亲属与年份信息，Max 高达 7.14
边界：采样也会出错；词汇一致不等于事实正确

结论、限制与成员分工

发现：Max 优于 Avg；1→5 个参考改善排序
K=20：AP 85.64%，接近论文 AUC-PR 85.63%
限制：传记域、单一生成模型、低频词与截断句
分工：张昊论文；赖轲楠实验；李方洲指标；李沐曦案例
下一步：各自核验材料，再在独立数据比较 BERTScore